

MA431 : Mathématiques appliquées à la sécurité

Regression Logistique

D. Barcelo

Grenoble INP ESISAR

2022/2023

- 1 La régression logistique
- 2 Détermination des coefficients du modèle
- 3 Exemple sous R
- 4 Evaluation du modèle
 - Courbe ROC
- 5 Bilan
- 6 Rappels et interprétation

Objectifs

- **Régression logistique** ou régression binomiale
- Objectif : **prévoir une variable binaire Y**
- A l'aide de p **variables explicatives continues** (notamment) : X_1, \dots, X_p .
- On observe $x = (x_1, \dots, x_p)$. On veut donc pouvoir déterminer $\mathbb{P}_{X=x}(Y = 1)$.
- Affectation de la valeur 1 à Y :
- Chercher une régression, c'est donc obtenir une relation de la forme :

$$\mathbb{P}_{X=x}(Y = 1) = \beta_0 + \sum_{i=1}^p \beta_i x_i$$

- Mais cela pose des problèmes ...

Résoudre les problèmes : odds

- Pour prendre une décision, on peut aussi prévoir un "odds" (côte ou rapport de chances).
- Affectation de la valeur 1 à Y :
- On peut donc chercher une relation de la forme :

$$\frac{\mathbb{P}_{X=x}(Y = 1)}{\mathbb{P}_{X=x}(Y = 0)} = \beta_0 + \sum_{i=1}^p \beta_i x_i$$

- Mais cela pose des problèmes ...


Résoudre les problèmes : fonction logit

- Une solution est de chercher une relation linéaire avec le logarithme de l'odds :
- Affectation de la valeur 1 à Y :
- La relation linéaire avec le logarithme de l'odds peut s'écrire :


$$\ln \left(\frac{\mathbb{P}_{X=x}(Y=1)}{1 - \mathbb{P}_{X=x}(Y=1)} \right) = \beta_0 + \sum_{i=1}^p \beta_i x_i$$

- Mais il y a d'autres modélisations ...

Modélisation logistique



Modélisation logistique



Modélisation logistique

On note $\pi(x) = \mathbb{P}_{X=x}(Y = 1)$.

On cherche à déterminer une relation de la forme :

$$\pi(x) = \frac{f\left(\beta_0 + \sum_{i=1}^p \beta_i x_i\right)}{1 + f\left(\beta_0 + \sum_{i=1}^p \beta_i x_i\right)}.$$

Modèle Logit :

$$\pi(x) = \frac{e^{(\beta_0 + \sum_{i=1}^p \beta_i x_i)}}{1 + e^{(\beta_0 + \sum_{i=1}^p \beta_i x_i)}}$$

et

$$\ln\left(\frac{\pi(x)}{1 - \pi(x)}\right) = \beta_0 + \sum_{i=1}^p \beta_i x_i$$

On note aussi $\text{Logit}(\pi(x)) = \frac{\pi(x)}{1 - \pi(x)}$.

Il existe d'autres modèles possibles (Probit et log-log notamment).

Autres modèles

On note $\pi(x) = \mathbb{P}_{X=x}(Y = 1)$.

On cherche à déterminer une relation de la forme :

$$\pi(x) = \frac{f\left(\beta_0 + \sum_{i=1}^p \beta_i x_i\right)}{1 + f\left(\beta_0 + \sum_{i=1}^p \beta_i x_i\right)}.$$

Modèle Log-Log :

$$\pi(x) = 1 - e\left(-e^{(\beta_0 + \sum_{i=1}^p \beta_i x_i)}\right)$$

et

$$\ln(-\ln(1 - \pi(x))) = \beta_0 + \sum_{i=1}^p \beta_i x_i$$

Courbe dissymétrique mais proche du logit.

Autres modèles

On note $\pi(x) = \mathbb{P}_{X=x}(Y = 1)$. On cherche à déterminer une relation de la forme :
$$\pi(x) = \frac{f\left(\beta_0 + \sum_{i=1}^p \beta_i x_i\right)}{1 + f\left(\beta_0 + \sum_{i=1}^p \beta_i x_i\right)}.$$

Modèle Probit :

$$\pi(x) = \Phi\left(\beta_0 + \sum_{i=1}^p \beta_i x_i\right)$$

et

$$\Phi^{-1}(\pi(x)) = \beta_0 + \sum_{i=1}^p \beta_i x_i$$

Avec Φ fonction de répartition de la loi normale centrée réduite.

Moins pratique et moins utilisé que le logit, minimise les cas extrêmes.

Odds

La modélisation $\ln \left(\frac{\pi(x)}{1 - \pi(x)} \right) = \beta_0 + \sum_{i=1}^p \beta_i x_i$ permet de calculer :

$$\frac{\pi(x)}{1 - \pi(x)} = \frac{\mathbb{P}_{X=x}(Y = 1)}{1 - \mathbb{P}_{X=x}(Y = 1)} = \frac{\mathbb{P}_{X=x}(Y = 1)}{\mathbb{P}_{X=x}(Y = 0)}$$

Il s'agit d'un odds (côte) : rapport mesurant la côte d'une modalité par rapport à une autre.

Règle d'affectation

- Le modèle logistique permet d'obtenir une estimation de $\ln \left(\frac{\pi(x)}{1 - \pi(x)} \right)$.
- Il faut pouvoir, pour un x donné, proposer une valeur à Y (0 ou 1).

Règle d'affectation

- Si $\pi(x) > 0,5$, on affecte la valeur 1 à Y .
- Si $\frac{\pi(x)}{1 - \pi(x)} > 1$, on affecte la valeur 1 à Y .
- Si $\beta x = \beta_0 + \sum_{i=1}^p \beta_i x_i > 0$, on affecte la valeur 1 à Y .

Estimation des coefficients

Pour estimer les coefficients β du modèle, on va utiliser la méthode du maximum de vraisemblance.

Le modèle est binomial, la vraisemblance va donc s'exprimer :

$$L(x_1, \dots, x_n, \beta) = \prod_{i=1}^n \pi(x_i)^{y_i} (1 - \pi(x_i))^{1-y_i}$$

◀ Rappels

Estimation des coefficients

Et la log-vraisemblance :

$$\ln L(x_1, \dots, x_p, \beta) = \sum_{i=1}^p y_i \ln(\pi(x_i)) + (1 - y_i) \ln(1 - \pi(x_i))$$

$$\ln L(x_1, \dots, x_p, \beta) = \sum_{i=1}^p y_i \ln \left(\frac{\pi(x_i)}{1 - \pi(x_i)} \right) + \ln(1 - \pi(x_i))$$

$$\ln L(x_1, \dots, x_p, \beta) = \sum_{i=1}^p y_i \beta x_i + \sum_{i=1}^p \ln(1 - \pi(x_i))$$

On peut donc, en maximisant la log-vraisemblance, obtenir une estimation $\hat{\beta}$ de β .

L'optimisation de la log-vraisemblance se fait à l'aide d'approximation numérique (algorithme de Newton-Raphson ou Fisher)

Qualité d'un modèle

Déviance

- Si on note $L(\beta_i)$ la vraisemblance du modèle avec i variables alors on définit la **déviance** : $D(\beta_i) = -2 \ln L(\beta_i)$.
- But de la régression logistique : maximiser $L(\beta_i)$ donc minimiser $D(\beta_i)$.
- La déviance permet de comparer des modèles emboîtés en ajoutant des variables explicatives supplémentaires à un modèle existant.
- La déviance est l'analogue de la somme des carrés résiduels en régression linéaire.
- La déviance suit asymptotiquement une loi du χ^2 .

Qualité d'un modèle

AIC

Critère d'Akaïké : $AIC = -2 \ln L(\beta_i) + 2(i + 1)$.

- permet de comparer des modèles, emboîtés ou non.
- L'AIC doit être le plus petit possible.
- peut aussi aider à déterminer le nombre de variables à sélectionner.

Exemple

Exemple de régression logistique.

◀ Exemple

Courbe ROC

Principe de la courbe ROC

Le modèle donne un résultat numérique avec un seuil s tel que la prédiction est positive si $x > s$ et négative si $x < s$.

Au fur et à mesure que s augmente alors :

- le taux de vrais négatifs augmente (spécificité).
- le taux de vrais positifs diminue (sensibilité).

La courbe ROC représente l'évolution de la spécificité (taux de vrais positifs) en fonction de 1-sensibilité (taux de faux négatifs).

Courbe ROC

Courbe ROC

- Visualiser le pouvoir discriminant d'un modèle.
- Courbe Receiver Operating Characteristic
- Représente $\alpha(s)$ en fonction de $1 - \beta(s)$

$\alpha(s) \approx$ Proportion de vrais positifs au score supérieur à s

$\beta(s) \approx$ Proportion de vrais négatifs au score supérieur à s


$1 - \beta(s) \approx$ Proportion de faux positifs au score supérieur à s

Courbe ROC

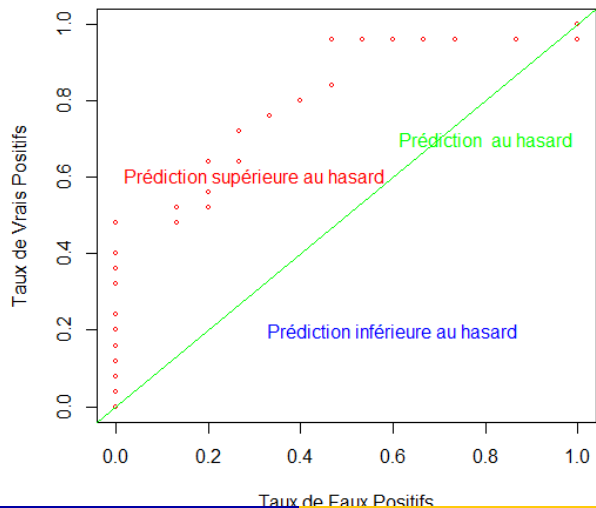
Courbe ROC

- Pour un seuil $s = 1$: Ni vrais positifs ni faux positifs donc point $(0;0)$
- Pour un seuil $s = 0$: Tous les vrais positifs et tous les faux positifs donc point $(1;1)$
- Modèle parfait : Tous les vrais positifs et aucun faux positifs
- Modèle aléatoire : Autant de vrais positifs que de faux positifs

Courbe ROC



Courbe ROC



Courbe ROC

Critère AUC

Pour comparer différentes modélisations logistiques : **critère AUC**

- Area Under the Curve
- Modèle performant qui sépare les vrais positifs des faux positifs : AUC proche de 1
- $AUC=0,5$: autant tirer à pile ou face les affectations
- $AUC<0,5$: autant tirer à pile ou face les affectations
- Comparaison de deux modèles : comparaison des AUC

La régression logistique :

- permet de traiter des variables explicatives de tout type,
- permet de traiter des variables à expliquer qualitatives,
- modèle précis et facilement programmables,
- peut s'appliquer aux petits échantillons,
- modélise directement une probabilité,
- possibilité de sélectionner pas à pas les variables explicatives
- **mais** c'est une approximation numérique (temps et précision),
- **mais** traite mal les valeurs manquantes et sensibilité aux valeurs hors normes de variables continues.

Rappels

Vraisemblance

Définition :

Soit X_1, X_2, \dots, X_n un échantillon, on appelle **vraisemblance** de l'échantillon la fonction :

$$L(x_1, \dots, x_n, \theta) = \prod_{i=1}^n \mathbb{P}(X_i = x_i, \theta)$$

si les X_i sont des v.a. discrètes et

$$L(x_1, \dots, x_n, \theta) = \prod_{i=1}^n f(x_i, \theta)$$

si les X_i sont continues.

La vraisemblance est interprétée comme l'information apportée par l'échantillon sur la population.

Maximum de vraisemblance

Définition :

On appelle **estimateur du maximum de vraisemblance** la valeur de $\hat{\theta}_n$ qui rend maximale la vraisemblance de l'échantillon.

$$L(x_1, \dots, x_n, \hat{\theta}_n) = \max_{\theta} L(x_1, \dots, x_n, \theta)$$

La vraisemblance $L(x_1, \dots, x_n, \theta)$ représente la probabilité d'observer (x_1, \dots, x_n) pour une valeur fixée de θ .

Si on a observé (x_1, \dots, x_n) sur un échantillon, on peut donc penser que θ prend la valeur la plus vraisemblable, i.e. celle qui fait que la probabilité d'observer (x_1, \dots, x_n) est la plus grande possible.

Maximum de vraisemblance

Généralement, la vraisemblance s'exprime sous la forme d'un produit, on va donc chercher à maximiser $\ln L$.

Si L est deux fois dérivable, on va alors résoudre :

$$\begin{cases} \frac{\partial \ln L}{\partial \theta}(x_1, \dots, x_n, \theta) = 0 \\ \frac{\partial^2 \ln L}{\partial \theta^2}(x_1, \dots, x_n, \theta) < 0 \end{cases}$$

Exemple

On dispose d'un échantillon de 40 individus sur lesquels on a relevé une variable binaire en observant une unique variable quantitative.

On effectue une regression logistique, voici les résultats :

Deviance Residuals :

| Min | 1Q | Median | 3Q | Max |
|---------|---------|--------|--------|--------|
| -1.8686 | -0.7764 | 0.3801 | 0.8814 | 2.0253 |

| Coefficients : | Estimate | Std. Error | z value | Pr(> z) | |
|----------------|----------|------------|---------|----------|------|
| (Intercept) | 5.9462 | 1.9599 | 3.034 | 0.00241 | Null |
| x | -0.1156 | 0.0397 | -2.912 | 0.00360 | |

deviance : 52.925 on 39 degrees of freedom

Residual deviance : 39.617 on 38 degrees of freedom

AIC : 43.617

- i) Interpréter ces résultats.
- ii) Déterminer le modèle.
- iii) On observe $x = 47$. Quelle classe doit-on attribuer ?

Exemple

Deviance Residuals :

| Min | 1Q | Median | 3Q | Max |
|---------|---------|--------|--------|--------|
| -1.8686 | -0.7764 | 0.3801 | 0.8814 | 2.0253 |

Distribution de la Déviance

| Coefficients : | Estimate | Std. Error | z value | Pr(> z) | Estimation |
|----------------|----------|------------|---------|----------|------------|
| (Intercept) | 5.9462 | 1.9599 | 3.034 | 0.00241 | |
| x | -0.1156 | 0.0397 | -2.912 | 0.00360 | |

des coefficients

On a donc comme modèle : $\ln \left(\frac{\pi(x)}{1 - \pi(x)} \right) = 5.9462 - 0.1156x$.

Les p_valeurs permettent de tester la nullité des coefficients.

Les Std. Error sont des écarts types qui permettent de réaliser des intervalles de confiance sur les coefficients.

Exemple

Null deviance : 52.925 on 39 degrees of freedom

Deviance nulle : déviance avec seulement la constante

Residual deviance : 39.617 on 38 degrees of freedom

Deviance : permet d'effectuer un test du χ^2 pour valider le modèle

Les deux déviances suivent une loi du χ^2 , leur différence également de degré de liberté la différence des degrés de libertés.

On a Deviance nulle - Déviance résiduelle $\sim \chi^2_1$.

On peut donc effectuer un test pour valider le modèle, l'hypothèse nulle est que les coefficients sont tous nuls contre une hypothèse alternative de non nullité d'au moins un des coefficients.

Un rejet de l'hypothèse nulle valide donc le modèle.

Deviance : permet de comparer des modèles emboîtés

AIC : 43.617 **AIC** : permet de comparer des modèles différents, pas forcément emboîtés.

← Cours